

Información complementaria al dataset

1. Representación de SWAN como un sistema de reglas borroso

Asumamos un variedad topológica de entrada \mathcal{I} y una variedad topológica de salida \mathcal{O} . El objetivo clásico en ML es aproximar un mapa $f : \mathcal{I} \rightarrow \mathcal{O}$ mediante una función surrogada \hat{f} tal que, dada una función de pérdida l , $\hat{f} = \min l(\mathcal{X})$ para un *dataset* \mathcal{X} . En términos más sencillos, el objetivo en ML es buscar una función que minimice el error de predicción de una salida dada una entrada.

Las redes neuronales plantean este problema mediante el uso de una composición de mapas entre variedades intermedias que permiten la transformación gradual de la entrada inicial en un valor similar al deseado.

De manera implícita, este planteamiento asume varios detalles notables:

1. Existe un mapa $f : \mathcal{I} \rightarrow \mathcal{O}$ perfecto, incluso si es desconocido
2. El *dataset* X es **representativo** del mapa deseado
3. Se dispone de muestras estadísticamente suficientes como para garantizar que el mínimo de error alcanzado aproxima el mínimo global de la función l
4. Todas las variedades topológicas empleadas en el proceso son variedades de Riemann

Es esperable, por tanto, que, dada un red neuronal $g = \hat{f}$ para un problema cualquiera, podamos aproximar su comportamiento mediante al menos una expresión matemática \hat{g} que represente el proceso de toma de decisiones de la red. Es decir, podemos definir una familia de funciones $\hat{G} = \{\hat{g} \simeq g\}$. Dado que $g = g$, por definición \hat{G} contendrá al menos a la propia red neuronal, que puede ser representada paramétricamente. Idealmente, \hat{G} contendrá también funciones más fácilmente interpretables.

Centrándonos en el caso concreto de SWAN, y por motivos que se explicarán un poco más adelante, podemos asumir que existe, al menos, una representación del modelo como un sistema de reglas borrosas. Estos sistemas se articulan en torno a dos tipos de funciones que colaboran: funciones de pertenencia \mathcal{M}_i y reglas de activación a_i . La idea intuitiva es la siguiente: dado un espacio latente \mathcal{L} , éste puede ser divididas en distintas regiones de manera borrosa. Cada región

contará con su correspondiente \mathcal{M}_i y a_i . Con esta definición, $\forall x \in \mathcal{I}$, $g(x) \simeq \sum_{i=1}^N \mathcal{M}_i(x) \cdot a_i(x)$.

El objetivo de este TFM es obtener valores aproximados para todas las a_i dada una segmentación determinada de \mathcal{L} .

2. Observaciones experimentales en SWAN

Para complementar un poco el planteamiento anterior, es importante tener en cuenta un par de observaciones principales que se han hecho en SWAN y que guían la hipótesis que estamos planteando.

2.1. Especialización en la atención

La estructura del codificador de SWAN está dividida en cinco ramas, todas ellas usando atención como mecanismo principal de funcionamiento. El objetivo principal era permitir a la red capturar la multimodalidad del viento solar (viento lento vs viento rápido, en términos muy gruesos). De forma muy resumida, una análisis de las activaciones de dichas ramas sugiere que, en efecto, ese objetivo se logró. Tanto es así que SWAN adapta su comportamiento a distintas entradas.

Detallar rama a rama sería excesivo para el objetivo de este documento, así que solo detallaré algunas líneas generales con la promesa de profundizar posteriormente en aquello que nos demos cuenta de que es necesario.

En primer lugar, ninguna rama se especializa en evaluar la velocidad. Todas tienden a usarla de algún modo, pero ninguna se centra en ella. Sin embargo, todas las demás variables de entrada cuentan con al menos una rama especializada en ellas. Es esperable, por tanto, que se estén usando para contextualizar la velocidad de distintas formas. Finalmente, una de las ramas parece actuar como rama directriz, y trabajar con secuencias completas de datos en lugar de con puntos específicos dentro de la matriz de entrada.

Observando la volubilidad de comportamiento que parece emerger de esta especialización tan marcada, parece razonable concluir que se trata de una de las grandes fortalezas de SWAN. Simultáneamente, es posible que precisamente esta adaptabilidad suponga un obstáculo para los algoritmos genéticos que se van a aplicar, así que conviene tenerla muy en cuenta.

2.2. Estructura de \mathcal{L}

Aunque el análisis dista de estar completo, \mathcal{L} parece presentar una estructura propia de una variedad de Riemann, como mínimo C^2 -suave, y con una estructura casi toroidal. Existe una marcada separación en dos grandes grupos, uno referente a viento lento y otro a viento rápido. Además, parece haber una segunda separación, menos clara, entre dos subgrupos de viento rápido. El hueco característico de un toroide puede deberse a la separación entre estos dos subgrupos.

Cabe destacar que, usando técnicas de *clustering* con una aproximación de la distancia mediante distancia Minkowski (generalización n -dimensional de la distancia euclídea), el número de *clusters* generados oscila entre 2 y 3, dependiendo de la configuración del algoritmo.

Aunque nos falta algo más de experimentación, la separación naif que hemos hecho de los datos parece razonable para que este TFM sirva, al menos, de prueba de concepto con una solidez razonable.

3. Correspondencias potenciales con la física del viento solar

Solo para tenerlas en cuenta de cara a analizar resultados. No pasa gran cosa si no aparecen claramente.

3.1. Probablemente verificables

- Presencia de una región de interacción entre viento lento y viento rápido cuando ambos se producen. Debería haber algún tipo de factor negativo asociado cuando se estima una aceleración del viento en el futuro, dado que se producirá un impacto antes de poder percibir el correspondiente aumento de velocidad.
 - Seguramente aparezca representada de forma dependiente a la densidad y la temperatura
 - El impacto en la predicción debería corresponder a un retraso de un día en la aparición del pico de velocidad en el viento solar
- Naturaleza del viento solar como un flujo continuo. Debería de haber una representación recursiva en términos de la velocidad de viento para la predicción de la propia velocidad

3.2. Difíciles de verificar

- Campo magnético como mecanismo de aceleración principal. No debería ser verificable porque la base de tiempos seguramente oculte el impacto de este fenómeno

4. Debilidades conocidas del modelo

En realidad hay una sola debilidad digna de mención, con dos vertientes: SWAN es incapaz de captar apropiadamente la aparición de eventos repentinos. Por evento repentino entendemos CMEs o agujeros coronales cuya forma ha cambiado drásticamente (y esto incluye tanto nuevos agujeros como agujeros que han desaparecido antes de lo previsto).

En principio, solo debería afectar si se intenta validar las expresiones resultantes contra observaciones de viento, pero es bueno tenerlo en cuenta en todo caso.